

GRANDES MODELOS DE LINGUAGEM · V2 · AULAS 1 A 8

Dossiê de diagnóstico conceitual

Avaliação 01 · Enunciado e instruções para estudantes

Analise situações de sistemas de linguagem, explique seus mecanismos e justifique decisões com base nos conteúdos estudados.

Organização	Individual, realizada fora da sala de aula.
Prazo	Uma semana: sete dias corridos. A abertura e a data final serão informadas no ambiente da turma; entrega até as 23h59 do dia final.
Dedicação estimada	4–6 horas, distribuídas ao longo da semana.
Entrega	Um único PDF com oito análises, duas variações de cenário, referências e declaração de uso de IA.
Pontuação	100 pontos: 80 nos casos e 20 nas variações.

O que será avaliado

Sua capacidade de identificar o problema, explicar como um mecanismo produz determinado comportamento, justificar uma decisão e reconhecer os limites das evidências. A relação entre as ideias importa mais que a quantidade de termos técnicos.

Escopo

Aula 1: tarefas e métricas. Aulas 2–4: tokenização, embeddings e interpretação do laboratório. Aulas 5–6: recorrência, atenção e máscara causal. Aula 7: posição e componentes do bloco Transformer. Aula 8: famílias de modelos e eficiência.

Sem desenvolvimento matemático

Não são exigidos cálculos, fórmulas, derivações, regressões ou demonstrações matemáticas. Também não é necessário programar, executar modelos, treinar sistemas ou contratar ferramentas. O uso de fórmulas não concede pontos extras.

Os oito casos são situações didáticas fictícias. Não é necessário coletar resultados reais para respondê-los.

ORIENTAÇÕES · LEIA ANTES DE COMEÇAR

Como realizar e entregar

1. Consulte e fundamente

A consulta aos materiais das aulas, às suas anotações e a fontes complementares é permitida. Em cada caso, indique uma referência específica, por exemplo: “Aula 6 — trecho sobre máscara causal”. Se usar fonte externa, informe título, autoria ou organização e link. Não há exigência de padrão bibliográfico formal.

2. Responda aos oito casos

Organize cada resposta em torno de: problema central, mecanismo, consequência ou decisão e fundamento consultado. Responda a todas as perguntas do caso. Você pode usar parágrafos, tópicos e diagramas explicados. Não basta nomear uma técnica; mostre sua relação com a situação.

3. Crie duas variações

Escolha um caso entre 1–4 e outro entre 5–8. Altere uma condição relevante de cada um e reavalie suas conclusões. As instruções completas estão na página 7.

4. Declare o uso de IA

Ferramentas de IA podem apoiar o estudo, a organização das ideias e a revisão. Você é responsável pelo conteúdo entregue: verifique os argumentos nos materiais e não apresente referências ou experimentos inexistentes. O uso de IA, por si só, não aumenta nem reduz a nota. A produção final é individual; não entregue respostas de colegas como suas.

Ao final, escreva: “Utilizei [ferramenta] para [finalidade]. Conferi ou alterei [partes] com base em [materiais]”. Caso não tenha utilizado, escreva: “Não utilizei IA neste trabalho”. Não é necessário anexar o histórico de conversas.

5. Prepare o arquivo

Entregue um único PDF, com texto selecionável e legível, pelo canal indicado no ambiente da turma. Nome sugerido: avaliacao01_nome_sobrenome.pdf. Identifique nome completo, turma e título no início. Use os títulos Caso 1 a Caso 8 e Variação 1 e Variação 2.

Extensão sugerida: 4–6 páginas, incluindo identificação e referências. Não é necessária uma capa separada. Os limites de extensão orientam a concisão; não geram desconto automático. Priorize respostas completas e evite repetir o enunciado.

Distribua o trabalho

Dias 1–2: leitura e consulta. Dias 3–4: redação dos casos. Dia 5: variações. Dia 6: revisão das justificativas e referências. Dia 7: conferência do PDF e envio. Esse cronograma é uma sugestão; haverá uma única entrega final.

PARTE 1 · ANÁLISE DOS CASOS

Tarefa e representação do texto

CASO 01 · AULA 1 · 10 PONTOS**Acerta muito, mas perde as urgências**

Uma central recebe principalmente solicitações comuns e algumas urgentes. Seu classificador marca praticamente tudo como “comum”. A equipe comemora a alta acurácia, mas solicitações urgentes continuam sem atendimento prioritário.

1. Por que a acurácia alta pode ser enganosa nesse cenário?
2. Qual tipo de erro merece atenção prioritária? Escolha uma métrica pertinente e explique o motivo, sem calculá-la.
3. Que consequência pode surgir se muitas solicitações comuns forem classificadas como urgentes? Como isso afeta a decisão?

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

CASO 02 · AULAS 2 E 4 · 10 PONTOS**Mesmo conteúdo, mais tokens**

Dois textos de conteúdo equivalente, um em português e outro em inglês, foram processados pelo mesmo tokenizador. Nesse teste, o texto em português produziu uma sequência mais longa de tokens.

1. Como a forma de construir o vocabulário e segmentar o texto pode produzir essa diferença?
2. Quais são as consequências para a ocupação da janela de contexto e para um serviço cobrado por token?
3. É possível concluir que português sempre exige mais tokens? Explique os limites do resultado e como faria uma comparação mais representativa.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

PARTE 1 · ANÁLISE DOS CASOS

Embeddings e evidências

CASO 03 · AULA 3 · 10 PONTOS

Uma palavra, dois contextos

Considere “Ela sentou no banco da praça” e “Ela abriu uma conta no banco”. Em um modelo Word2Vec estático, a palavra “banco” possui um único vetor compartilhado entre suas ocorrências.

1. Por que essa representação limita a distinção entre os dois sentidos?
2. O que uma representação contextual permite fazer de diferente?
3. Relacione sua explicação à ideia de aprender representações a partir dos contextos de uso das palavras.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

CASO 04 · AULAS 3 E 4 · 10 PONTOS

O gráfico convenceu a equipe

Uma equipe treinou embeddings em um corpus pequeno. Em uma projeção t-SNE, algumas palavras aparecem próximas. A equipe concluiu: “O modelo compreendeu os significados e funcionará bem em qualquer domínio”.

1. Identifique duas limitações dessa conclusão, considerando a visualização e os dados utilizados.
2. Proponha uma verificação adicional que ajude a avaliar a representação aprendida. Não é necessário executá-la.
3. Diga que observação apoiaria sua análise e o que ainda não seria possível concluir mesmo com um resultado favorável.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

PARTE 1 · ANÁLISE DOS CASOS

Da recorrência à atenção

CASO 05 · AULA 5 · 10 PONTOS**O começo da frase se perdeu**

Um sistema de tradução recorrente comprime a entrada inteira em um único vetor antes de gerar a tradução. Em frases longas, detalhes do começo frequentemente se perdem.

1. Explique o gargalo associado a concentrar a informação da entrada em um único vetor.
2. Como a consulta aos diferentes estados do encoder por atenção pode ajudar durante a geração?
3. O uso de LSTM elimina, por si só, a dependência do processamento sequencial? Justifique.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

CASO 06 · AULAS 5 E 6 · 10 PONTOS**Bom no treinamento, ruim na geração**

Um modelo foi treinado para prever o próximo token. Uma inspeção revelou que suas posições podiam consultar tokens posteriores, inclusive aquele que deveriam prever. No treinamento, o resultado parecia excelente; na geração, a qualidade caiu.

1. Explique a diferença entre a informação disponível no treinamento descrito e na geração. Qual é a função da máscara causal?
2. Na self-attention, explique os papéis de Q, K e V e por que essas representações podem ser produzidas a partir da mesma entrada.
3. O que múltiplas cabeças de atenção permitem representar? Evite atribuir a cada cabeça uma função fixa obrigatória.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

PARTE 1 · ANÁLISE DOS CASOS

Bloco, família e eficiência

CASO 07 · AULAS 6 E 7 · 10 PONTOS

As peças do Transformer

Uma equipe está montando um encoder com self-attention bidirecional, sem qualquer informação de posição. O sistema precisa distinguir “o cachorro morde o homem” de “o homem morde o cachorro”.

1. Explique por que a configuração descrita apresenta uma dificuldade para representar a diferença de ordem.
2. Diferencie as funções de informação posicional, conexão residual, normalização e feed-forward.
3. Por que essas peças não substituem automaticamente umas às outras? Diferencie também informação posicional de permissão de acesso entre posições.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

CASO 08 · AULA 8 · 10 PONTOS

Escolher e sustentar o modelo

Uma empresa precisa classificar mensagens em categorias fixas e também oferecer um assistente que produza respostas abertas. O assistente funciona com poucas conversas, mas enfrenta falta de memória quando aumentam a quantidade de conversas simultâneas e o comprimento dos históricos.

1. Indique uma família de modelo candidata para cada tarefa e justifique pela forma de produzir a saída. Declare as condições relevantes para sua escolha.
2. Explique como a memória pode aumentar mesmo sem alteração dos pesos, considerando o KV cache.
3. Diferencie o que três propostas tentam reduzir: compartilhar K/V entre cabeças, usar atenção em janelas e treinar um modelo menor por destilação. Cite uma limitação de pelo menos uma delas.

Resposta sugerida: 100–180 palavras, em texto ou tópicos. Inclua a referência ao material utilizado.

PARTE 2 · 20 PONTOS

Duas variações de cenário

O objetivo desta parte é mostrar como sua explicação se adapta quando uma condição do problema muda. Produza duas variações: uma de um caso entre 1–4 e outra de um caso entre 5–8.

Para cada variação, apresente

- 1. Caso de origem e condição alterada.** Identifique o caso e descreva precisamente o que mudou. Mantenha as demais condições claras.
- 2. Conclusão revisada.** Explique qual decisão, previsão ou interpretação de sua resposta original precisa mudar e por quê.
- 3. Conclusão preservada.** Identifique o que continua válido e justifique com o conceito pertinente.
- 4. Verificação proposta.** Descreva uma observação, comparação ou teste que ajudaria a avaliar a nova conclusão. Diga que resultado a apoiaria ou a colocaria em dúvida. Não execute o teste nem invente resultados.

O que caracteriza uma alteração relevante?

Uma alteração que mude a análise: o objetivo da tarefa, a consequência de um erro, as características dos dados, a informação disponível, o formato de saída ou uma restrição do sistema. Trocar apenas nomes de empresas ou palavras, preservando o mesmo raciocínio, não é suficiente.

Exemplos de direções possíveis

No caso 1, você pode mudar a consequência operacional de um falso positivo. No caso 8, pode mudar o tipo de saída exigido ou a restrição de atendimento. Esses exemplos indicam a natureza da mudança; cabe a você construir o novo cenário e argumentar.

Modelo de organização

Campo	O que escrever
Caso de origem	Número do caso e breve identificação.
Nova condição	O que mudou e quais condições foram mantidas.
O que muda	Nova conclusão e explicação do mecanismo.
O que permanece	Conclusão preservada e sua justificativa.
Como verificar	Observação proposta e interpretação dos resultados possíveis.

Extensão sugerida: 150–250 palavras por variação. As duas variações valem 10 pontos cada.

CRITÉRIOS E CONFERÊNCIA FINAL

Como o trabalho será avaliado

Parte 1 — oito casos, 10 pontos cada

Critério por caso	Pontos
Correção conceitual e explicação do mecanismo: identifica o problema e explica como ele ocorre.	6
Aplicação e limites: responde ao cenário, justifica consequências ou decisões e evita generalizações indevidas.	3
Fundamentação: relaciona a explicação a um trecho ou tema identificável do material consultado.	1
Subtotal: oito casos	80

Parte 2 — duas variações, 10 pontos cada

Critério por variação	Pontos
Condição alterada de forma relevante e cenário claramente definido.	2
Conclusão revisada com justificativa conceitual coerente.	4
Identificação e justificativa do que permanece válido.	2
Verificação pertinente e interpretação dos resultados possíveis.	2
Subtotal: duas variações	20

Como os critérios serão aplicados

Atendimento completo: argumento correto, conectado ao cenário e suficiente para responder ao solicitado. Atendimento parcial: há compreensão, mas faltam relações ou justificativas. Atendimento insuficiente: apenas nomes ou definições soltas, contradições centrais ou ausência de resposta. Cada critério admite pontuação parcial.

Escolhas alternativas são aceitas quando tecnicamente defensáveis e coerentes com as condições declaradas. Aparência gráfica, quantidade de jargão e inclusão de fórmulas não recebem pontos extras. A nota total vai de 0 a 100.

Antes de enviar

Confira: identificação; oito casos respondidos; uma variação de cada bloco; referências localizáveis; declaração de IA; arquivo PDF legível, com texto selecionável e sem páginas cortadas. Abra o arquivo final e confirme o envio no ambiente da turma.

Materiais de base: ementa e materiais das aulas 1 a 8 da versão 2 da disciplina Grandes Modelos de Linguagem: do Transformer aos Agentes de IA.