

Resumo Attention is All You Need

O artigo apresenta o Transformer, uma nova arquitetura de inteligência artificial proposta por Engenheiros da Google que mudou completamente a forma de como os computadores processam linguagem. Antes do Transformer, os modelos usavam RNNs que liam as frases palavra por palavra como se fosse uma fila, o que tornava o processo lento e dificultava o entendimento de relações entre as palavras.

O diferencial do Transformer foi abandonar essa leitura em sequência e usar apenas um mecanismo chamado de atenção. Com ele, o modelo consegue olhar para a frase inteira de uma só vez e decidir quais palavras são as mais importantes para entender cada parte do texto, independente se elas estão juntas ou não.

Esse padrão arquitetural trouxe diversas vantagens como: o modelo não depende mais de processar as palavras uma de cada vez, o treinamento se tornou mais rápido e paralelizável... entre outras. Além disso, os resultados obtidos em tarefas de tradução automática superaram todos os modelos anteriores, e com um custo computacional bem menor, e o modelo ainda se mostrou capaz de generalizar bem para outras tarefas de linguagem.

Em resumo, o que os Engenheiros da Google criaram foi uma inovação que fez os computadores pararem de olhar palavra por palavra e entenderem o contexto do texto, focando apenas no que realmente importa. Essa mudança foi tão eficiente que se tornou a base de praticamente todos os modelos de LLMs que utilizamos hoje em dia.