

Grandes Modelos de Linguagem: do Transformer aos Agentes de IA

Sessenta horas. No fim delas vocês não vão ter aprendido sobre LLM — vocês vão ter construído um.



Contrato da disciplina (avaliação • prova • política de IA • os 8 labs • projeto): apresentado na sessão de recepção. Documento de uma página no canal da turma.



As duas frases estão certas. As duas conclusões estão erradas.

(1) "O detector de fraude atingiu 99,0% de acurácia no conjunto de teste."

→ 01:12

→ caso desbalanceado

→ recall = 0% → não pega nenhum caso

(2) "Nosso modelo tem perplexidade 4,0 — bem melhor que o baseline publicado, que reporta 20."

→ 01:33

→ calculado por token

→ se usarem tokenizers ≠

Nenhuma das duas contém erro de cálculo. As duas são verdadeiras — e as duas levam a uma decisão errada.

Uma métrica de não mente

→ Qual pergunta a métrica responde?

→ Quais erros a métrica esconde?

→ qual unidade?

→ Qual decisão?

Cinco saltos, sessenta anos

ChatGPT não foi um salto de arquitetura — a arquitetura é de 2017. Foi um salto de interface e de alinhamento.

1966

Regras

ELIZA — padrão e reescrita

teto: nenhum modelo de língua

↳ procurava palavras/estruturas
devolvia respostas pré-definidas

↳ "Eu estou preocupado com meu trabalho."

↳ "Porque você está preocupado com x"

90-00

Estatística

n-gramas — língua como
distribuição contada

↳ como quais palavras aparecem
juntas.

teto: esparsidade

↳ inteligência → artificial

↳ aumento o tamanho
do agrupamento/sequência

↳ o número de combinações e
sequências não aparece nos
dados de treinamento.

2013

Vetores densos

Word2Vec — semântica como
geometria

↳ palavras com significado
parecido, possuem a
ocupar espaços próximos.

teto: vetor estático, sem
contexto

2017

Atenção

Transformer — dependência
longa e paralelismo

↳ forma central
de relacionar pontos
distantes de uma
sequência

o mesmo mecanismo resolve
os dois

2020

Escala e instrução


GPT-3 e o pós-treino —
aprendizado em contexto

completador vira
assistente

Eu fui no parque e fiquei no banco
menos trabalho humano, mais dados e computação →

banco financeiro

RLHF



POR QUE LLM VIROU INFRAESTRUTURA

O gargalo mudou de lugar

- a. Uma interface de texto substitui N modelos especializados.
- b. O custo de tentar uma tarefa nova caiu de "montar dataset rotulado" para "escrever um prompt".
- c. A mesma pilha serve produto, ferramenta interna e automação.

modelagem →

avaliação + engenharia de sistema

É a razão dos Módulos 5 a 7 — e a razão de esta aula gastar 45 minutos em métricas.



DEMONSTRAÇÃO AO VIVO

Uma caixa de texto, quatro tarefas

Quatro tarefas que dez anos atrás eram quatro projetos de mestrado. Zero treino, uma caixa de texto.

1. sentimento em uma palavra
2. entidades em JSON
3. tradução PT→EN
4. resumo em uma frase
5. contar n-gramas em comum – **as duas divisões:** pelo candidato e pela referência



Três famílias — e o critério é a assinatura da função

A família não é o assunto do texto. É a assinatura da função.

Entrada → Saída

↳ formato; tarefa

texto → 1 rótulo

↳ formato

Classificação de sequência

sentimento, intenção, tópico, idioma

retorna um enum

"Não consigo acessar minha conta"

↳ PROBLEMA - ACESSO

Entrada

texto → 1 rótulo/token

Rotulagem de tokens (NER)

NER, classe gramatical, parsing

retorna lista do tamanho da entrada

Ana trabalha no CESAR

↳ Pessoa: Ana

local trabalho: CESAR

Nome Entity Recognition

texto → texto livre

Geração

tradução, QA, sumarização, código

retorna string de tamanho livre

Na demo, rotulagem foi resolvida por geração — a tarefa continua a mesma, o modelo virou um só. Cada família herdou métricas próprias, e é isso que o intervalo separa do que vem depois.

Avaliação diferente

↳ Métricas



A métrica não mentiu. Eu escolhi a métrica errada.

```
def eh_fraude(transacao):
    return False # uma linha, zero treino
```

10.000 → 9.900 e 100 fraudes

pred +

pred -

real +

VP = 0

FN = 100

real -

FP = 0

VN = 9.900

$N = 10.000$ · $\pi = 1\%$ · a coluna vazia é o argumento

$$\text{acurácia} = \frac{VP + VN}{N}$$

$$\text{precisão} = \frac{VP}{VP + FP}$$

$$\text{revocação} = \frac{VP}{VP + FN}$$

$$F_1 = \frac{2 \cdot P \cdot R}{P + R}$$

$$1 - \pi = 99\%$$

O classificador trivial já entrega esse número de graça. A régua não é 50%.

Matriz de Confusão

	P	N
T	TP	TN
F	FP	FN

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{9900}{10000} = 99\%$$

$$\text{Precisão} = \frac{TP}{TP + FP}$$

$$\text{Recall} = \frac{TP}{TP + FN}$$

Precisão é "das vezes que apitei, quantas eram falta". Revocação é "das faltas, quantas apitei".

Precisão = dentre todas as vezes que o modelo acusou fraude, quantas ele acertou

Recall = entre todas as fraudes existentes, quantas detectei

→ derivação completa: Apêndice A.1 (slide 15)

Qual detector vai para produção?

modelo	<u>VP</u>	<u>FP</u>	FN	VN	acurácia	precisão	revocação
trivial (return False)	0	0	100	9.900	0,9900	—	0,00
conservador	20	5	80	9.895	$\frac{20+9895}{10.000} = \frac{9915}{10.000} = 99,15\%$	$\frac{20}{20+5} = 0,8 = 80\%$	$\frac{20}{20+80} = 20\%$
agressivo	90	900	10	9.000	$\frac{90+9.000}{10.000} = \frac{9090}{10.000} = 90,90\%$	$\frac{90}{90+900} = 9,1\%$	$\frac{90}{90+10} = 90\%$

$N = 10.000$ · fraude real = 100 casos ($\pi = 1\%$) · a primeira linha vem resolvida como exemplo de leitura

- Os seis números que faltam.
- Qual dos três vai para produção numa triagem de fraude — e o que a acurácia disse sobre essa escolha.

F₁ E F₂


F Score $\rightarrow$ F₂-Score
 $\hookrightarrow$ Média Harmônica

$P = 1$; $R = 0,1$
 $\frac{P+R}{2} = \frac{1+0,1}{2} = 0,55$ ponder.

Um número para dois, e quem escolhe o peso não é a matemática


Um detector omisso: apita raramente e acerta quando apita. $P = 1,00 \cdot R = 0,01$

Três médias do mesmo par $H \leq G \leq A$



A aritmética premia com 0,5 um sistema que perde 99% dos casos.
A harmônica devolve 0,02 — ela é dominada pelo menor dos dois.

Mesmo sistema, três perguntas $P = 0,30 \cdot R = 0,90$



Os três números estão certos e respondem perguntas diferentes.
Escolher β é dizer quanto custa um falso negativo — e isso é decisão de produto.

F₁ não é a métrica certa: é a escolha de dizer que um falso negativo e um falso positivo custam o mesmo.

F₂ $\hookrightarrow$ A média harmônica entre P e R .
 $\hookrightarrow$ Atribuindo ao P e R o mesmo peso.

$$F_{\beta} = \frac{(1+\beta^2)PR}{\beta^2P + R}$$

 $\beta > 1 \rightarrow$ recall
 $\beta < 1 \rightarrow$ precision

β não é uma escolha matemática

$\hookrightarrow$ Negócio/Problema
 $\hookrightarrow$ Qual erro é mais aceitável?

MÉTRICAS DE GERAÇÃO

A mesma contagem, duas divisões, duas ordenações opostas

Sobreposição ≠ verdade; utilidade, semanticamente equivalente

→ Precision

BLEU = $BP \cdot \exp(\sum w_n \log p_n)$ precisão de n-gramas "o que eu escrevi está no gabarito?"

ROUGE = ROUGE-N | ROUGE-L revocação de n-gramas "quanto do gabarito eu cobri?"

→ Sobreposição de n-gramas

referência r: o gato está sobre o tapete

candidato A: o gato no tapete (curto)

candidato B: o gato está deitado sobre o grande tapete velho

(prolixo)

→ frase que deveria ser gerada

Sem a penalidade de brevidade, escrever pouco seria a estratégia ótima.

→ dentre todas palavras geradas, qts estiveram na referência.

candidato A: $\frac{3}{4} = 0,75 \rightarrow$ precisão; $\frac{3}{6} = 0,50 \rightarrow$ recall *→ das palavras da referência quantas gerei*

unigramas em comum

p_1 (BLEU, precisão)

ROUGE-1 (revocação)

		<i>→ curta</i>	
candidato A	3	$3/4 = 0,750 \uparrow$	$3/6 = 0,500$
candidato B	6	$6/9 = 0,667$	$6/6 = 1,000 \uparrow$

Mesmo numerador, denominadores diferentes, ordenações invertidas: a precisão prefere A, a revocação prefere B.

Cada métrica é remendada do lado em que é degenerada.

→ BLEU: Apêndice A.3 (slide 17) • ROUGE: Apêndice A.4 (slide 18)

o | ga | b | a | r | e | | s | o | b | r | e | o | l | a | p | e | f | e

A MÉTRICA QUE DISPENSA GABARITO

corpus
↓
conjunto de
texto
do qual
modelo
treinado

PPL = $\exp(\text{loss})$ — e por que ela não atravessa tokenizadores

$$\text{PPL} = \exp\left(-\frac{1}{N} \sum \log P(t_i | t_{<i})\right) = \exp(H)$$

- PPL = 12 é estar tão indeciso quanto quem escolhe **opções**, não entre 12 opções — a unidade é erro.
- Um modelo uniforme sobre $|V|$ símbolos tem $\text{PPL} = |V|$ — o teto de quem chuta.
- loss é o número que o laço de treino imprime — é o que vocês vão ver na tela no Lab 2.

Perplexidade é medida **por token**. Trocar o tokenizador não deixa a comparação imprecisa — deixa sem sentido.


mesmo modelo, $r = 4$ caracteres/subword · comparar "4" com o "20" publicado é comparar 256 com 20 · o de subword tem BPC = 1,08 e é melhor

→ derivação e conversão de unidades: Apêndice A.5 (slide 19)

perplexidade = 12

↳ um nível de incerteza ao escolher uniformemente entre 12 possibilidades

↳ quantidade de opções
256



BPC = 2,00 nos dois casos

ONDE A MÉTRICA DE REFERÊNCIA QUEBRA

A dívida de avaliação

proximidade de estilo
entre a referência e
o gerado
↳ Sobreposição

Sobreposição de n-gramas assume que existe uma resposta certa. Quando há muitas respostas boas e diferentes, a métrica não mede qualidade — mede estilo.

CASO 1 · PARÁFRASE

BLEU-4 = 0,000

c = o gato está no tapete
r = o gato está sobre o tapete

Português correto e mais natural. $p_4 = 0/2$ zera a média geométrica.

CASO 2 · SINÔNIMO

BLEU-4 = 0,000

c = o felino está sobre o carpete
 $p_1 = 0,667 \cdot p_2 = 0,400 \cdot p_3 = 0,250 \cdot p_4 = 0$

Mesmo comprimento, BP = 1. E ROUGE não salva: revocação 0,667, F_{lcs} 0,667.

CASO 3 · O INVERSO

nota alta

Resposta errada que reaproveita as palavras da referência. A métrica é sensível à forma e cega ao conteúdo.

A gente ficou excelente em gerar texto e continua ruim em julgar texto. Medir é um problema de engenharia próprio — rubrica humana, acordo entre anotadores e LLM-as-judge calibrado são a Aula 27.

quanto maior o conjunto de palavras possíveis, pior é medir com sobreposição. ↳ Corpus → conjunto de texto de treinamento.

Da tarefa à métrica

A coluna que vale não é a da métrica. É a da falha que a métrica não vê.

CENÁRIO	FAMÍLIA	MÉTRICA	O QUE ELA NÃO VÊ
1. Roteador de tickets em 12 filas, com uma fila crítica a 2% do volume			
2. Extração de número de processo e nome das partes em petições jurídicas			
3. Tradução PT→EN de descrições de produto de e-commerce			
4. Detector de discurso de ódio em comentários, com revisão humana a jusante			
5. Assistente que responde sobre o regulamento da universidade, citando a fonte			

Unificamos o modelo. Não unificamos as métricas.

- 01 Três famílias de tarefa com métricas próprias, construídas em décadas.
- 02 Um único modelo resolvendo as três sem treino, só mudando a caixa de texto.
- 03 Porque tudo foi reescrito como "prever o próximo token" — e as métricas não vieram junto.

Esse desequilíbrio é o assunto das próximas vinte e nove aulas.

SETUP PARA O LAB 1 — FOTOGRAFE

- ☐ conta Google / Colab
- ☐ conta Hugging Face
- ☐ provedor de API com free tier

Leitura dirigida: por que perplexidade só é comparável com o mesmo tokenizador?

apêndice · A.1 matriz de confusão · A.2 F_1 e F_β · A.3 BLEU
· A.4 ROUGE · A.5 perplexidade

Aula 2 — Tokenização: antes de prever o próximo token, alguém decide o que é um token.

Matriz de confusão e as quatro métricas

Notação e identidade

VP/FP/FN/VN particionam o conjunto; $P^+ = VP + FN$ são os positivos reais; $\pi = P^+/N$ é a prevalência. A classe positiva é escolha do avaliador, e trocá-la troca precisão com revocação.

$$VP + FP + FN + VN = N$$

$$\text{acurácia} = (VP + VN) / N$$

$$\text{precisão} = VP / (VP + FP)$$

$$\text{revocação} = VP / (VP + FN) = VP / P^+$$

A acurácia trata FP e FN como o mesmo erro. A precisão divide pelo que o modelo declarou; a revocação, pelo que o mundo tem — um é escolha do modelo, o outro é fato do conjunto.

Derivação do piso trivial

$T = \text{"responde sempre negativo"}$

$$VP = 0 \cdot FP = 0 \cdot FN = P^+ \cdot VN = P^-$$

$$\text{acurácia}(T) = P^-/N = (N - P^+)/N = 1 - \pi$$

$$\text{revocação}(T) = 0$$

$$\text{precisão}(T) = 0/0 \rightarrow \text{indefinida (convenção: 0)}$$

Qualquer problema com prevalência π entrega $1 - \pi$ de acurácia a quem não faz nada. O intervalo útil tem largura π : com $\pi = 0,01$, a acurácia informativa vive entre 0,99 e 1,00 — e a diferença entre um modelo inútil e um perfeito é o segundo decimal.

A tabela do slide 8, conferida

modelo	VP	FP	FN	VN		acur.	prec.	revoc.
trivial	0	0	100	9.900		0,9900	—	0,00
conservador	20	5	80	9.895		0,9915	0,800	0,200
agressivo	90	900	10	9.000		0,9090	0,091	0,900

O agressivo tem a **pior** acurácia e é o único que serve para triagem: acha 90 das 100. O conservador tem a **melhor** acurácia e acha um quinto das fraudes — passa em revisão de resultado e falha em produção.

Casos-limite

- $\pi \rightarrow 0$: acurácia do trivial $\rightarrow 1$, métrica sem poder discriminante (evento raro).
- $\pi = 0,5$: piso 0,5 — único regime em que "acima de 50%" faz sentido.
- $FP = 0$ com $VP > 0$: precisão 1 é sinal de omissão, não de qualidade.
- $VP + FP = 0$: precisão 0/0; a convenção muda a média multiclasse.

Multiclasse e geometria

$$\text{macro-}F_1 = (1/K) \sum F_1(\text{classe } k) \quad \text{cada classe pesa igual}$$

$$\text{micro-}F_1 = F_1 \text{ sobre VP, FP, FN somados}$$

Micro é dominado pelas classes frequentes. É o cenário 1 do slide 13: a fila crítica a 2% só aparece no macro. Varrendo o limiar, $(FP/P^+, VP/P^+)$ traça a curva ROC — a acurácia reporta **um ponto** e cala sobre a curva, e é por isso que ela inverte a ordenação.

F₁ como média harmônica, e F_β

Derivação da média harmônica

$$\begin{aligned} H(P,R) &= 1 / [(1/2)(1/P + 1/R)] = 2 / (1/P + 1/R) \\ 1/P + 1/R &= (R + P) / (P \cdot R) \\ H(P,R) &= 2 / [(P+R)/(P \cdot R)] = 2 \cdot P \cdot R / (P+R) = F_1 \quad \blacksquare \end{aligned}$$

Por que harmônica — com números

$$\begin{aligned} P &= 1,00 & R &= 0,01 \\ \text{aritmética} &= (1,00 + 0,01)/2 & &= 0,505 \\ \text{geométrica} &= \sqrt{1,00 \cdot 0,01} & &= 0,100 \\ \text{harmônica} &= 2 \cdot (1,00 \cdot 0,01) / (1,00 + 0,01) & &= 0,0198 \\ H \leq G \leq A & \text{ com igualdade só se } P = R \end{aligned}$$

A aritmética premia com 0,5 um detector que perde 99% dos casos. A harmônica é a mais próxima do menor dos dois valores — e é essa a propriedade desejada.

Cota útil: vale sempre $H(P,R) \leq 2 \cdot \min(P,R)$. Sem perda de generalidade $R \leq P$, então $P + R \geq 2R$ e $2PR/(P+R) \leq P$; e $2PR/(P+R) \leq 2R$ porque $P/(P+R) \leq 1$. F_1 nunca é mais que o dobro do pior nem ultrapassa o melhor.

Generalização: F_β

$$\begin{aligned} F_\beta &= (1 + \beta^2) \cdot P \cdot R / (\beta^2 \cdot P + R) \\ \beta = 1 &\rightarrow 2PR/(P+R) = F_1 \quad \checkmark \end{aligned}$$

$$F_\beta = 1 / [(1-w)/P + w/R] \quad \text{com } w = \beta^2/(1+\beta^2)$$

β^2 é a **razão de importância** entre revocação e precisão: com $\beta = 2$, a revocação vale 4 vezes a precisão na média ponderada.

Triagem médica com $\beta = 2$

$$\begin{aligned} P &= 0,30 & R &= 0,90 \\ F_1 &= 0,54 / 1,20 & &= 0,450 \\ F_2 &= 1,35 / 2,10 & &= 0,643 \\ F_{0,5} &= 0,3375 / 0,975 & &= 0,346 \end{aligned}$$

O mesmo sistema vale 0,346, 0,450 ou 0,643 conforme o β . Reportar F_1 sem justificar $\beta = 1$ é assumir em silêncio que um falso negativo e um falso positivo custam o mesmo.

Casos-limite e escolha de β

- $P = 0$ ou $R = 0 \rightarrow F_\beta = 0$ para todo β : sem nota parcial.
- $P = R \rightarrow F_\beta = P$: o peso deixa de importar.
- $\beta \rightarrow 0$ dá P ; $\beta \rightarrow \infty$ dá R .
- F_1 de conjuntos com prevalências diferentes não é comparável: P depende de π , R não.
- Operacionalmente, $\beta^2 \approx c_{FN} / c_{FP}$ — e esses custos não estão no conjunto de dados.

BLEU: precisão de n-gramas com penalidade de brevidade

Precisão modificada e truncamento

A precisão ingênua é quebrável: contra $r = \text{o gato está sobre o tapete}$, o candidato $o \ o \ o \ o$ teria 5/5. Truncar pela contagem máxima nas referências resolve.

$$p_n = \sum \min(\text{count}_c(g), \text{count}_{\max}(g)) / \sum \text{count}_c(g) \\ \rightarrow \text{count}_c(o) = 5, \text{count}_{\max}(o) = 2 \Rightarrow p_1 = 2/5 = 0,40$$

Média geométrica e penalidade

$$\text{BLEU} = \text{BP} \cdot \exp(\sum w_n \log p_n) = \text{BP} \cdot \prod p_n^{w_n} \\ \text{com } w_n = 1/N \Rightarrow \text{raiz } N\text{-ésima do produto}$$

$$\text{BP} = 1 \quad \text{se } |c| > |r| \\ \text{BP} = \exp(1 - |r|/|c|) \quad \text{se } |c| \leq |r|$$

Um único $p_n = 0$ zera o BLEU inteiro — a aritmética não faria isso. E como não há termo de revocação, a BP é o remendo que impede a estratégia de escrever pouco.

Os dois candidatos do slide 10, com BP

	p_1	ROUGE-1	BP	BLEU-1
A	$3/4=0,750$	$3/6=0,500$	$\exp(1-6/4)=0,6065$	0,455
B	$6/9=0,667$	$6/6=1,000$	$ c \triangleright r \rightarrow 1,000$	0,667

A paráfrase que zera o BLEU-4

$$r = \text{o gato está sobre o tapete} \quad (|r| = 6) \\ c = \text{o gato está no tapete} \quad (|c| = 5)$$

$$p_1 = 4/5 = 0,800 \quad p_2 = 2/4 = 0,500 \\ p_3 = 1/3 = 0,333 \quad p_4 = 0/2 = 0,000 \\ \text{BP} = \exp(1 - 6/5) = 0,8187$$

$$\text{BLEU-4} = 0,8187 \cdot 0^{1/4} = 0,000 \\ \text{BLEU-2} = 0,8187 \cdot \sqrt{0,400} = 0,518$$

A tradução é boa: BLEU-4 dá zero porque a média geométrica funciona como definida.

O sinônimo, e o degrau

$$c = \text{o felino está sobre o carpete} \quad (|c| = |r| = 6) \\ p_1 \ 0,667 \cdot p_2 \ 0,400 \cdot p_3 \ 0,250 \cdot p_4 \ 0 \cdot \text{BP} = 1 \Rightarrow \text{BLEU-4} = 0 \\ \text{uma só troca (o carpete): } p_4 = 0,667 \Rightarrow \text{BLEU-4} = 0,760$$

Uma troca dá 0,760; duas dão 0,000. A queda é um degrau, não uma rampa.

Casos-limite

- Qualquer $p_n = 0$ zera BLEU — daí BLEU de corpus e suavização.
- $|c| = 1$ correto: $p_1 = 1$ mas $\text{BP} = \exp(1 - |r|) \approx 0,0067$ com $|r| = 6$.
- BLEU = 1 exige coincidência literal com uma referência.
- Tokenizações ou números de referências diferentes não são comparáveis.

Papineni et al., *BLEU* (ACL 2002).

ROUGE-N e ROUGE-L

A troca de denominador

$$\text{ROUGE-N}_{\text{rev}} = \frac{\sum_{g \in G_n(r)} \min(\text{count}_c, \text{count}_r)}{\sum_{g \in G_n(r)} \text{count}_r(g)}$$

O numerador é o mesmo de p_n ; o denominador troca de $G_n(c)$ para $G_n(r)$. É literalmente a diferença entre precisão e revocação aplicada a n-gramas.

r = o gato está sobre o tapete (6 unigramas)
 c = o gato está no tapete
 $\text{ROUGE-1}_{\text{rev}} = 4/6 = 0,667$ (contra $p_1 = 4/5 = 0,800$)
 $\text{ROUGE-1}_{\text{prec}} = 4/5 = 0,800$ $\text{ROUGE-1}_{F_1} = 0,727$

Os candidatos do slide 10, com F

A rev $3/6=0,500$ prec $3/4=0,750$ $F_1 = 0,600$
 B rev $6/6=1,000$ prec $6/9=0,667$ $F_1 = 0,800$

B é prolixo e diz o que a referência não diz, e ainda assim tem revocação perfeita — revocação não pergunta o que sobrou. A F é o remendo simétrico ao da BP em BLEU: com ela, B volta a ganhar.

ROUGE-L e a recorrência da LCS

$$\begin{aligned} L[i,0] &= L[0,j] = 0 \\ L[i,j] &= L[i-1,j-1] + 1 && \text{se } c_i = r_j \\ L[i,j] &= \max(L[i-1,j], L[i,j-1]) && \text{se } c_i \neq r_j \\ LCS &= L[m,k] && \text{custo } O(m \cdot k) \end{aligned}$$

c = o gato está no tapete $\rightarrow LCS = 4$
 $R_{lcs} = 4/6 = 0,667$ $P_{lcs} = 4/5 = 0,800$
 $F_{lcs} = 0,727$

Se os últimos tokens coincidem, o token entra na subsequência e o problema reduz aos prefixos. Se não, ao menos um deles não participa da LCS. ROUGE-1 e ROUGE-L coincidem aqui porque as palavras em comum já estavam na ordem certa; elas divergem sob reordenação.

Casos-limite

- c contém r inteira mais 200 palavras: $R_{lcs} = 1$ e P_{lcs} minúscula.
- c é permutação de r : ROUGE-1 = 1 e ROUGE-L bem abaixo.
- Sinônimos (caso 2 do slide 12): $\text{ROUGE-1}_{\text{rev}} = 4/6 = 0,667$ e $F_{lcs} = 0,667$ — caem junto com BLEU.
- Múltiplas referências: toma-se o máximo, o que infla o número.

BLEU é a pergunta do revisor; ROUGE é a do professor de resumo. As duas contam **forma** — trocar de métrica de sobreposição não resolve o slide 12. Fazer essa pergunta é a Aula 27.

Lin, *ROUGE* (2004).

Perplexidade, e por que ela não atravessa tokenizadores

Entropia cruzada e a derivação

$$H = -(1/N) \sum \log P_{\theta}(t_i | t_{\{<i\}}) = -\log P_{\theta}(\text{texto})/N$$

$$\text{PPL} = \left(\prod 1/P_{\theta}(t_i | t_{\{<i\}}) \right)^{1/N}$$

$$\log \text{PPL} = -(1/N) \sum \log P_{\theta}(t_i | t_{\{<i\}}) = H$$

$$\text{PPL} = \exp(H) \quad \blacksquare$$

A média é geométrica porque probabilidades se multiplicam ao longo da sequência: a raiz N-ésima devolve "a probabilidade típica por token". H é a log-verossimilhança total dividida pelo número de tokens — é essa forma que expõe o problema de comparabilidade.

Por que exp(loss)

A perda que o laço de treino minimiza é a entropia cruzada média **por token** — é o mesmo H. Duas ressalvas do Lab 2: a média tem de ser por token (não por lote) e os tokens de padding têm de estar mascarados, senão o loss cai por diluição e a perplexidade sai otimista sem nada ter melhorado.

O teto trivial

$$\text{uniforme: } H = \log|V| \Rightarrow \text{PPL} = |V|$$

$$\text{PPL} > |V| \text{ não é modelo fraco: é bug}$$

$$\text{PPL} < 1 \text{ é impossível } (P \leq 1 \Rightarrow H \geq 0)$$

A conta da incomparabilidade

$$\log \text{PPL}_A = -\log P(\text{texto})/N_A$$

$$\log \text{PPL}_B = -\log P(\text{texto})/N_B$$

$$\Rightarrow \log \text{PPL}_B = (N_A/N_B) \cdot \log \text{PPL}_A$$

$$\Rightarrow \text{PPL}_B = \text{PPL}_A^r \quad \text{com } r = N_A/N_B$$

$$\text{PPL}_{\text{car}} = 4,0 \Rightarrow H = \ln 4 = 1,386 \text{ nat/caractere}$$

$$r = 4 \Rightarrow H_{\text{sub}} = 5,545 \Rightarrow \text{PPL}_{\text{sub}} = 256$$

Mesmo modelo, mesmo texto. A diferença é uma **potência**, não um fator — reescalar pela fertilidade não conserta. E muda o espaço de eventos: prever entre 90 caracteres e entre 32.000 subwords são tarefas diferentes. A comparação é sem sentido, não imprecisa.

Bits por caractere: a normalização que compara

$$\text{BPC} = \log_2(\text{PPL}_{\text{token}}) \cdot (N_{\text{token}} / N_{\text{caractere}})$$

$$\text{caractere: } \log_2(4,0) \cdot 1 = 2,00$$

$$\text{subword: } \log_2(256)/4 = 2,00 \quad \checkmark \text{ mesmo modelo}$$

$$\text{subword real com PPL 20: } \log_2(20)/4 = 1,08 \rightarrow \text{melhor}$$

Casos-limite e onde isto reaparece

- PPL = 1 em validação é vazamento, não maestria.
- $P_{\theta} = 0$ dá $H = \infty$ — com softmax não ocorre; com $\log(0)$ na mão, sim.
- Textos de avaliação diferentes: tão inválido quanto tokenizadores diferentes.
- $|V|$ diferentes mudam o teto: "PPL 90" é chute em caractere e excelente em 50 k.
- Aula 2: r medido como fertilidade. Lab 2: PPL = exp(loss) na mão do aluno.