

Embeddings e representações vetoriais.

O documento está na base. A busca devolve zero. Três sintomas, uma causa — e a geometria como resposta.

Docente

docente@cesar.org.br

Agosto / 2026

O documento está na base. A busca devolve zero.

CONSULTA

médico

0 documentos

em 10.000 indexados

$\cos = 0,00$

DOCUMENTO QUE EXISTE NA BASE

O atendimento **clínico** é conduzido pelo **doutor** responsável, no **ambulatório** da unidade.

Nenhuma dessas palavras é a palavra digitada.

O sistema não errou a conta. A conta deu zero porque a representação não tem onde guardar semelhança.

Três falhas diferentes, e o mesmo buraco embaixo.

BPE · WordPiece · Unigram → o texto virou [4021, 8977, 312]

a

A busca do slide anterior: o documento certo com semelhança zero.

RESOLVE HOJE · SLIDES 4-7

b

banco de dinheiro e banco de praça recebem **um** vetor.

FICA EM ABERTO · AULA 6

c

rei - homem + mulher ≈
rainha funciona no modelo
baixado e falha no de vocês.

EXPLICA HOJE · SLIDE 8


O ID é um endereço, não uma quantidade — e endereço não se soma.

Todas as palavras equidistantes de todas as palavras.

```
gato    = [0, 0, 1, 0, 0, ..., 0]   |V| = 50 000
gatinho = [0, 1, 0, 0, 0, ..., 0]
gato · gatinho = 0 → cos(gato, gatinho) = 0
```

- **Esparsidade** (chata): 50 000 dimensões para carregar um inteiro. Resolve-se com engenharia.
- **Ortogonalidade** (fatal): produto interno 0 entre quaisquer duas palavras distintas, por construção.
- Mil frases com médico não movem nada em clínico.

O problema do one-hot não é o desperdício de memória. É que a semelhança que a busca precisava não existe na representação.



ângulo 90° = cosseno 0 = nenhuma semelhança utilizável

Matriz de Gram = identidade. Derivação, contagem e por que hashing não resolve: A.1.

Uma palavra é conhecida pelas companhias que ela mantém.

Firth (1957); formulação distribucional em Harris (1954).

Operacionalização: mesmos contextos → vetores próximos.
Critério programável, não afirmação filosófica.

Ancestral direto: matriz de coocorrência + redução de dimensionalidade. O Word2Vec troca contagem por predição.

A ressalva que a hipótese obriga: ela não diz “sinônimos ficam próximos”. quente e frio ocorrem nos mesmos contextos e ficam próximos. Antônimos vizinhos são consequência, não bug.

O TESTE DO GLORP

O barista serviu um **glorp** fumegante.

Tomei três **glorps** antes da prova.

Ela prefere **glorp** sem açúcar.

Formalização, PMI e por que a polaridade é invisível ao sinal: **A.3**.

Isso não é uma bonita frase de linguística. É um critério que dá para programar.

De 50 000 dimensões binárias para 100 dimensões reais.

ONE-HOT



$|V|$ dimensões · valores em $\{0,1\}$

uma posição informativa

cosseno sempre 0

DENSO

$[0,21 \ -0,88 \ 0,04 \ 1,37 \ -0,52 \ 0,66 \ -0,11 \ 0,90 \ 0,33 \ -1,04]$


d entre 50 e 1024 · valores reais

toda posição informativa

perto/longe e direção significam algo

Nenhuma dimensão é interpretável isoladamente. Não existe “a dimensão da realeza”; as direções semânticas são combinações das dimensões.

Treinar, nesta aula: ajustar números por gradiente até um erro medido parar de cair. O mecanismo formal é da Aula 12.



A régua mede direção, não tamanho.


$$\cos(u, v) = (u \cdot v) / (\|u\| \|v\|) \text{ faixa: } -1 \dots 1$$

O **numerador** mede alinhamento; o **denominador** joga fora o comprimento dos dois vetores; o resultado é o cosseno do ângulo.

Por que não distância euclidiana: num espaço treinado a **norma correlaciona com a frequência** — e frequência não é o que se compara quando se pergunta se dois sentidos são parecidos.

Cosseno **não é probabilidade**.
0,7 não é “70% parecido”.

Cosseno **não é comparável entre espaços**. Compara-se ordenação, não valor.



Derivação, contraexemplo numérico e a esfera unitária: A.2.



Cosseno mede direção e joga a magnitude fora — e é isso que eu quero, porque a magnitude conta frequência, não sentido.

Funciona no modelo da internet, falha no modelo de vocês.

$$\text{vec}(\text{rei}) - \text{vec}(\text{homem}) + \text{vec}(\text{mulher}) \approx \text{vec}(\text{rainha})$$

Uma **relação** virou uma **direção** — e a mesma direção vale partindo de vários pontos. Ninguém programou regra de gênero.

- O protocolo padrão **exclui as três palavras de entrada** dos candidatos.
- Categorias inteiras falham; país→moeda é notoriamente ruim, e a demo vai tentar.
- O efeito enfraquece muito em corpus pequeno — o regime exato do Lab 1.



A analogia funciona porque a relação é uma direção. Não porque o modelo sabe o que é um rei. Objetivo e falhas: A.5.

DEMONSTRAÇÃO AO VIVO

Quatro medições: o zero, os vizinhos, a analogia que falha e o **bank**.


1. one-hot em NumPy → matriz 4×4 de cossenos: 1,00 na diagonal, 0,00 nos 12 pares
2. vizinhos de king, python, hospital num espaço denso pré-treinado
3. duas analogias → gênero (forte) e país→moeda (fraca)
4. vizinhos de bank → finanças e margem de rio na MESMA lista

A Medição 1 é a evidência dos slides 2 e 4; a Medição 3, do slide 8; a Medição 4 é a evidência do slide 13 — e roda quarenta minutos antes dele.

`codigo/demo-embeddings.py`


Duas tarefas rasas, dois espaços diferentes.

CBOW



1 exemplo por janela. Mais rápido, melhor em palavras frequentes.

skip-gram



Vários pares por janela. Mais lento, melhor em palavras raras e corpus pequeno.

Janela: pequena (± 2) captura substituíbilidade — vizinho de Recife é outra cidade; grande (± 10) captura tópico — vizinho de Recife é praia, frevo.

CBOW pergunta “que palavra cabe no buraco?”. Skip-gram

pergunta “que companhias esta palavra tem?”. Objetivo escrito: A.4.

Cem mil classes viraram k+1 perguntas de sim ou não.

Ingênuo: o softmax normaliza sobre todo o vocabulário a cada exemplo — $|V| \approx 10^5$, bilhões de exemplos. Não fecha em nenhum orçamento.


Reescrita: dado um par (palavra, contexto), ele é real ou sorteado? Classificação binária.

k negativos por positivo (5 a 20), de uma unigrama **distorcida** — frequência elevada a 3/4.

$$\log \sigma(v_c \cdot v_w) + \sum_{i=1..k} \log \sigma(-v_{n_i} \cdot v_w)$$
$$\sigma(x) = 1 / (1 + e^{-x})$$

Não é aproximação preguiçosa do softmax: é outro objetivo — e o objetivo trocado produz embeddings melhores para este fim.

SOFTMAX COMPLETO



100 000

saídas normalizadas por exemplo

AMOSTRAGEM NEGATIVA


(gato, sofá)	sim
(gato, parafuso)	não
(gato, imposto)	não
(gato, quilômetro)	não
(gato, sinfonia)	não
(gato, vinagre)	não

6

decisões binárias por exemplo

Custo por exemplo cai de $|V|$ para k+1: cerca de **17 mil vezes menos**. Derivação e o expoente 3/4: **A.4**.

O modelo é descartável. A tabela é o produto.



Ninguém quer um preditor de palavra de contexto — esse modelo é jogado fora.

O produto é a **matriz de embedding**, que numa visão ingênua seria só um parâmetro interno do treino.

O treino é **auto-supervisionado**: o rótulo vem do próprio texto — por isso escala para qualquer quantidade de texto que exista.

A mesma jogada, escalada: “prever o próximo token” também não interessa por si. Interessa o que o modelo precisa aprender para acertá-la (Aula 12).

O modelo que eu treinei é lixo. Eu queria a tabela de pesos que ficou dentro dele.


Um vetor, dois sentidos, nenhum bem representado.

banco de dinheiro, de praça, de dados, de areia — **um único vetor** para todos.

Evidência da Medição 4: os vizinhos de bank trouxeram credit e river na mesma lista. Não é ruído: é o vetor sendo exatamente o que ele é.

O vetor vira um compromisso — cai numa região que não descreve bem nenhum dos sentidos. Mesmo com manga, ponto, letra.

Treinar mais e aumentar d não resolvem, e a razão é a interface: a operação é consulta a uma tabela por ID. A frase não participa da conta.



Resolve na **Aula 6** — $\text{softmax}(\mathbf{QK}^T/\sqrt{d_k})\mathbf{V}$. De tabela para função.

O problema não é falta de dados. É que a frase não entra na conta — e isso não se conserta hoje.

Três itens, decisão escrita nos três.

1 · ORDENAR POR COSSENO ESPERADO, COM UMA FRASE DE JUSTIFICATIVA POR PAR

médico
enfermeiro

gato
parafuso

quente
frio

Recife
Fortaleza

comer
comida

COSSENO ALTO

COSSENO BAIXO

2 · ESCOLHER A JANELA

(a) sugerir termos substituíveis num campo de busca; (b) agrupar documentos por assunto. Uma frase de justificativa.

3 · DIAGNOSTICAR

As analogias falham quase todas nos embeddings próprios; o mesmo teste funciona no modelo baixado.

CAUSA

EVIDÊNCIA QUE CONFIRMA

Nenhum dos três pede uma conta. Os três podem saber o que a geometria prevê.

Significado virou posição. Falta virar função da frase.

(a) a busca que não achava **RESOLVIDO**

posição + cosseno
como régua

(c) analogia no corpus pequeno **EXPLICADO**

cauda esparsa
+ exclusão
(A.5)

(b) banco com um vetor só **ABERTO**

a frase não entra na
conta → **Aula 6**

Aula 4 — Laboratório 1: BPE do GPT × WordPiece do BERT no mesmo texto · razão de tokens PT/EN · Word2Vec em corpus português com gensim · PCA/t-SNE, vizinhos e analogias.

CHECKLIST DO LAB 1 — FOTOGRAFE

- Colab aberto
- gensim=4.3.3 com scipy<1.14
- **runtime reiniciado após instalar**
- modelo em cache (~100 MB)

Pergunta dirigida: quais analogias vão falhar num corpus de poucos megabytes, e por quê? Hipótese escrita antes de rodar.

One-hot: ortogonalidade mútua e a ausência de generalização

NOTAÇÃO E PREMISSAS

$e_i[m] = 1$ se $m = i$, 0 caso contrário. Indexação injetiva; nenhuma informação além do índice entra na representação — é essa premissa que os vetores densos abandonam.

PRODUTO INTERNO

$$\begin{aligned}\langle e_i, e_j \rangle &= \sum_m e_i[m] \cdot e_j[m] = \delta_{ij} \\ E E^T &= I \quad (\text{base ortonormal}) \\ \cos(e_i, e_j) &= \delta_{ij} / (1 \cdot 1) = \delta_{ij}\end{aligned}$$

Só há parcela não nula quando $m = i$ e $m = j$ ao mesmo tempo. Representação matematicamente impecável — e é essa perfeição que a torna inútil aqui.

A EUCLIDIANA NÃO SALVA

$$\begin{aligned}\|e_i - e_j\|^2 &= 1 + 1 - 0 = 2 \\ \|e_i - e_j\| &= \sqrt{2} \quad (\text{todo par } i \neq j)\end{aligned}$$

Trocar de métrica não cria informação que não está na representação.

POR QUE IMPEDE GENERALIZAÇÃO

$$\begin{aligned}z &= W^T e_i = (\text{linha } i \text{ de } W)^T \\ \partial L / \partial W[j] &\equiv 0 \quad \text{para todo } j \neq i\end{aligned}$$

Cada palavra tem seu próprio conjunto de parâmetros, estatisticamente independentes por construção. Mil frases com médico não movem um número de clínico. Com $d \ll |V|$ as palavras passam a compartilhar dimensões — esse acoplamento é o que se chama generalização.

CONTAGEM

$|V| = 50\,000$, float32: 200 KB por vetor, um número não nulo. 1 000 tokens = 200 MB. Denso com $d = 100$: 400 bytes — **500x menos**, e com semelhança utilizável.

POR QUE HASHING NÃO RESOLVE

1. Sem colisão, a ortogonalidade sobrevive: cosseno continua 0. **2.** Com colisão, os vetores ficam idênticos (cosseno 1) — e a colisão é sorteada pela função de hash, não pelo sentido. Troca-se “nenhuma semelhança” por “semelhança arbitrária”.

CASOS-LIMITE

$|V| = 1$: não há par — o problema é relacional.

$|V| = 2$: ortogonalidade já está lá. **Multi-hot** (caracteres/n-gramas): cosseno deixa de ser zero — intuição do FastText, e prova que a culpa é do “um índice por palavra”.

One-hot é uma lista de endereços, não um mapa. A aula constrói a planta. → **volta ao slide 4.**

Similaridade de cosseno, e por que não distância euclidiana

DEFINIÇÃO E FAIXA

$$\begin{aligned}\langle u, v \rangle &= \|u\| \|v\| \cos \theta \\ \cos(u, v) &= \langle u, v \rangle / (\|u\| \|v\|) \\ -1 \leq \cos \leq 1 &\quad (\text{Cauchy-Schwarz})\end{aligned}$$

Igualdade a 1 sse $v = \lambda u$ com $\lambda > 0$; a -1 sse $\lambda < 0$. Zero = ortogonalidade — o caso de A.1.

INVARIÂNCIA DE ESCALA

$$\cos(\alpha u, \beta v) = \cos(u, v) \quad \forall \alpha, \beta > 0$$

Quem escolhe cosseno declara: o comprimento do vetor não é informação relevante para esta pergunta.

RELAÇÃO COM A EUCLIDIANA E O CONTRAEXEMPLO

$$\begin{aligned}\|u-v\|^2 &= \|u\|^2 + \|v\|^2 - 2\|u\|\|v\|\cos \\ u &= (8, 0) \quad v = (2, 0) \quad a = (5, 0) \quad b = (2, 5; 4, 330) \\ \cos(u, v) &= 1,000 \quad \cos(a, b) = 0,500 \\ \|u-v\| &= 6,000 \quad \|a-b\| = 5,000\end{aligned}$$

As duas medidas **discordam**: o cosseno elege (u, v) , a euclidiana elege (a, b) . E é exatamente o caso do espaço de palavras: casa (frequente, norma grande) e residência (rara) têm direções parecidas e normas diferentes. A pergunta é sobre sentido; o cosseno responde 1,000, a euclidiana joga o par para trás.

QUANDO SÃO EQUIVALENTES

$$\begin{aligned}\|u\| = \|v\| = 1 &\Rightarrow \|u-v\| = \sqrt{2 - 2\cos} \\ t \mapsto \sqrt{2-2t} &\text{ é estritamente decrescente}\end{aligned}$$

Na esfera unitária, ordenar por cosseno = ordenar por euclidiana. É o que permite um índice vetorial de produto interno servir para busca por cosseno — fundamento operacional da Aula 18.

DUAS LEITURAS ERRADAS · CASOS-LIMITE

Não é probabilidade ($0,7 \neq$ “70% parecido”). Não é comparável entre espaços — em d alto os cossenos se concentram numa faixa estreita. Vetor nulo: indefinido (convenção 0,0). $\cos < 0$ raramente é antônimo — pela hipótese, antônimos ficam próximos. $d = 1$: só ± 1 , a régua perde toda resolução.

Jogar a norma fora é jogar a frequência fora. →
volta ao slide 7.

A hipótese distribucional, formalizada

NOTAÇÃO E A HIPÓTESE ESCRITA

$$\begin{aligned} \hat{p}(c|w) &= \#(w,c) / \#(w) \\ \text{se } p(\cdot|w_1) &\approx p(\cdot|w_2) \\ \text{então } \psi(w_1) &\approx \psi(w_2) \end{aligned}$$

Escrita assim, deixa de ser afirmação sobre significado e passa a ser **especificação de função**: procura-se $\psi: V \rightarrow \mathbb{R}^d$ em que proximidade reflita proximidade de distribuições. É aí que a frase de 1957 vira engenharia.

PREMISSAS, E ONDE FALHAM

A janela define o contexto (trocar L troca a relação medida). Ordem é ignorada — “o gato mordeu o homem” e o inverso geram os mesmos pares. O corpus é assumido representativo: um corpus esportivo não sabe o que é derivada.

COOCORRÊNCIA, E A CORREÇÃO PELA PMI

$$\text{PMI}(w,c) = \log[p(w,c) / (p(w)p(c))]$$

$$\begin{aligned} p(w) &= 0,001 & p(c) &= 0,05 & p(w,c) &= 0,0004 \\ \text{esperado} &= 0,00005 \end{aligned}$$

$$\text{PMI} = \log(0,0004/0,00005) = \log 8 \approx 2,08$$

A contagem crua responde “com que frequência?”; a PMI responde “mais do que o acaso explicaria?” — a pergunta certa. Esparsidade se contorna com PPMI = $\max(0, \text{PMI})$ e SVD truncada (LSA).

A ponte: o skip-gram não constrói matriz nenhuma, e ainda assim seu ótimo satisfaz $v_c \cdot v_w = \text{PMI} - \log k$ (Levy & Goldberg, 2014). Contar-e-fatorar e prever-direto chegam ao mesmo objeto.

ANTÔNIMOS PRÓXIMOS É TEOREMA, NÃO BUG

quente e frio ocupam a mesma posição sintática e o mesmo campo semântico: “a água está ___”. As distribuições são quase idênticas, e a janela não registra polaridade — logo os vetores **devem** ficar próximos. Mais dados não conserta: melhora a estimativa de duas distribuições que continuam iguais. Exige supervisão externa ou representação contextual (Aula 6).

CASOS-LIMITE

Ocorrência única: distribuição degenerada, vetor é ruído — razão de existir `min_count`. **Palavra ambígua:** estima-se a mistura $\alpha p_1 + (1-\alpha) p_2$ — é o banco do slide 13 escrito como equação, e nenhum d maior resolve. **Distribuições idênticas:** limite de identificabilidade. $L \rightarrow \infty$: aprende-se tópico, não substituíbilidade.

→ volta ao slide 5.

Skip-gram com amostragem negativa: o objetivo e o que ele aproxima

O OBJETIVO INGÊNUO NÃO FECHA

$$p(c|w) = \exp(v_c \cdot v_w) / \sum_{\{c' \in V\}} \exp(v_{\{c'\}} \cdot v_w)$$

$|V|=10^5$, 10^9 pares $\rightarrow 10^{14}$ exp por época

Não é problema de constante: é ordem de grandeza errada.

A REESCRITA BINÁRIA

$$\begin{aligned} P(y=1|w,c) &= \sigma(v_c \cdot v_w) \\ \ell(w,c) &= \log \sigma(v_c \cdot v_w) \\ &\quad + \sum_{i=1..k} \log \sigma(-v_{\{n_i\}} \cdot v_w) \end{aligned}$$

Um atrator e k repulsores. $\sigma(-x)$ e não $-\sigma(x)$ porque a decisão negativa também é verossimilhança.

NÃO É SOFTMAX PREGUIÇOSO — É PMI DESLOCADA

$$v_c \cdot v_w = \text{PMI}(w,c) - \log k$$

NCE inclui $\log(k \cdot P_n(c))$ e recupera o softmax; a amostragem negativa **descarta** esse termo — é outro problema de otimização. No ótimo ela **fatora implicitamente** a matriz de PMI de A.3, sem nunca materializá-la. Aumentar k desloca o alvo para baixo: só pares com PMI alta sobrevivem.

NEGATIVOS E O EXPOENTE 3/4

$$\begin{aligned} P_n(c) &\propto \#(c)^{3/4} \\ (0,1/0,001)^{3/4} &\approx 31,6 \end{aligned}$$

Escolha empírica do artigo, sem derivação. O que ela faz é comprimir razões de frequência: $100 \rightarrow 31,6$, **3,2x menos desproporcional**.

CUSTO

softmax:	$ V \cdot d$	por par
negativa:	$(k+1) \cdot d$	por par
razão:	$100 \cdot 000/6 \approx 16 \cdot 667$	

HIPERPARÂMETROS DO LAB 1

sg=1 — mais pares por janela; melhor em palavra rara

window=L — pequeno: substituíbilidade; grande: tópico

negative=k — repulsores e o nível de PMI que sobrevive

vector_size=d — precisão da fatoração

min_count — **corta o vocabulário**: a palavra deixa de existir

CASOS-LIMITE

$k=0$: colapso, tudo colinear. $k \rightarrow \infty$: alvo vai a $-\infty$.
 $d \geq |V|$: decora par a par. CBOW: o mesmo objetivo com a média do contexto.

Mikolov 1301.3781 · Levy & Goldberg 2014.

→ slide 11.

@CESAR 2026 | Todos os Direitos Reservados

Analogias vetoriais: o objetivo, e o que elas não provam

O QUE SE CALCULA (3COSADD)

$$x^* = \operatorname{argmax}_{\{x \in V \setminus \{a, b, c\}\}} \cos(v_x, v_b - v_a + v_c)$$

com $\|v\|=1$ e $t = v_b - v_a + v_c$:

$$\cos(v_x, t) = [\cos(x, b) - \cos(x, a) + \cos(x, c)] / \|t\|$$

$\|t\|$ não depende de $x \rightarrow$ não afeta o argmax

O que parece “resolver uma equação vetorial” é **maximizar uma soma de três similaridades**: parecido com b , parecido com c , diferente de a . Não há inferência na operação.

POR QUE EXCLUIR $\{A, B, C\}$ É INDISPENSÁVEL

$$\operatorname{escore}(x=b) = 1 - \cos(b, a) + \cos(b, c)$$
$$\operatorname{escore}(x=c) = \cos(c, b) - \cos(c, a) + 1$$

O termo 1 domina: sem exclusão o vencedor é tipicamente b ou c , porque $v_b - v_a$ é pequeno em norma e t fica perto do ponto de partida. Quem lê “75% de acurácia” e conclui “resolve 3 de 4 analogias” está lendo um número mais forte do que o medido.

POR QUE CATEGORIAS INTEIRAS FALHAM

O método pressupõe que a relação seja **uma direção quase constante**. Vale em plural, gênero, grau — marcações regulares e frequentes. Falha quando cada par é um fato isolado: Japão $\rightarrow$ iene não compartilha regularidade com Brasil $\rightarrow$ real; a média de pares isolados é ruído. E real também é adjetivo — vetor de mistura (A.3).

POR QUE FALHA EM CORPUS PEQUENO

$$v_b - v_a = (v_{b^*} - v_{a^*}) + (\epsilon_b - \epsilon_a)$$

sobrevive enquanto $\|v_{b^*} - v_{a^*}\| \gg \eta\sqrt{2}$

1. Menos ocorrências $\rightarrow \eta$ cresce, a magnitude da relação não. 2. `min_count` corta a cauda: rainha, iene não têm vetor — o teste nem roda. 3. Vocabulário pequeno tem menos distratores, mas também menos chance de conter a resposta. Word2Vec: 10^9 palavras; Lab 1: $\sim 10^6$ — outro regime, não o mesmo com menos dados.

PROVA · NÃO PROVA

Prova: uma relação frequente deixou uma componente linear detectável, sem ninguém escrever regra. **Não prova:** raciocínio; que o modelo sabe o que é um rei; pureza da relação (vieses — Bolukbasi, 1607.06520); acurácia fora do protocolo.

GABARITO DO ITEM 3 DO EXERCÍCIO

Cauda esparsa/min_count $\rightarrow$ imprimir o vocabulário e ver quais palavras ficaram fora.

Exclusão $\rightarrow$ rodar sem excluir $\{a, b, c\}$ e ver b ou c vencerem. $\rightarrow$ slide 8.